



空间统计与分析

Spatial Statistics and Analysis

涂 伟

深圳大学城市空间信息工程系

2026年3月25日



第二章 聚类与分类

Clustering and Classification



主要内容

- 聚类
- 分类



物以类聚



鸟巢聚集栖息



人居聚集




星团

“A group of the same or similar elements gathered or occurring closely together”

- ❑ 物以类聚是客观世界的有序性描述，事物都在不同层次水平上聚合。
- ❑ 传统分类和聚类，主要依靠经验和专业知识来实现。
- ❑ 随着生产技术和科学的发展，数据量变大，要求也越高，凭经验和专业知识不能进行确切分类。

聚类



二维平面坐标系下样本的不同聚集模式


聚类 (Clustering)： 将一组样本组织为不同的类别或层次结果，使得相同类别之内的相似性越高，不同类别之间的差异性越大。

按照现代地理学辞典，聚类为按一定标准，鉴别地理区域或实体、现象之间的接近程度，并将相接近的归为一类的数学方法。


.

相似性度量


- 为了衡量不同样本上亲疏程度，需要度量样本和类别间的相似性。
- 相似性度量利用样本的一些指标（特征或变量组合）进行计算。
- 不同的相似性度量可以反映在样本**特征空间**上的距离或角度等。



颜色相似的样本



RGB波段的
特征空间映射



在RGB颜色空间上的样本相似度量

相似性度量

对于 m 个指标的两个样本可用向量表示： $\mathbf{x}_i = (x_1, x_2, \dots, x_m)$ 和 $\mathbf{y} = (y_1, y_2, \dots, y_m)$ 。

其常用的相似度量方法包括：

- 欧式距离（直线距离）

$$dist = \sqrt{\sum_{i=1}^m (x_i - y_i)^2}$$

- 相关系数

$$r = \frac{\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^m (x_i - \bar{x})^2 \cdot \sum_{i=1}^m (y_i - \bar{y})^2}}$$

其中， $\bar{x}$ 和 $\bar{y}$ 分别为 $\mathbf{x}$ 和 $\mathbf{y}$ 指标的均值。

- 余弦相似性

$$cos = \frac{\sum_{i=1}^m x_i y_i}{\sqrt{\sum_{i=1}^m x_i^2} \sqrt{\sum_{i=1}^m y_i^2}}$$

相似性度量

某地区9个农业区的7项经济指标数据

区 代号	人均 耕地 x_1 / ($\text{hm}^2 \cdot \text{人}^{-1}$)	劳均 耕地 x_2 / ($\text{hm}^2 \cdot \text{个}^{-1}$)	水田 比重 x_3 /%	复种 指数 x_4 /%	粮食 单产 x_5 / ($\text{kg} \cdot \text{hm}^{-2}$)	人均粮食 x_6 / ($\text{kg} \cdot \text{人}^{-1}$)	稻谷 占粮 食比 重 x_7 /%
G_1	0.294	1.093	5.63	113.6	4 510.5	1 036.4	12.2
G_2	0.315	0.971	0.39	95.1	2 773.5	683.7	0.85
G_3	0.123	0.316	5.28	148.5	6 934.5	611.1	6.49
G_4	0.179	0.527	0.39	111	4 458	632.6	0.92
G_5	0.081	0.212	72.04	217.8	12 249	791.1	80.38
G_6	0.082	0.211	43.78	179.6	8 973	636.5	48.17
G_7	0.075	0.181	65.15	194.7	10 689	634.3	80.17
G_8	0.293	0.666	5.35	94.9	3 679.5	771.7	7.8
G_9	0.167	0.414	2.9	94.8	4 231.5	574.6	1.17

数据标准化：大多数相似性度量要求所有指标具有统一的量纲。如量纲不一致：

- 对量纲级别较高的指标，可能会假相扩大它所刻画事物属性的差异。
- 对量纲级别较低的指标，可能会假相缩小它所刻画事物属性的差异。

相似性度量

- 标准差标准化(Z-Score标准化): 令新样本的值 x_{ij} 为

$$x'_{ij} = \frac{x_{ij} - \bar{x}_{.j}}{s_j}$$

其中, $\bar{x}_{.j}$ 和 s_j 分别为第 j 个指标的均值和方差;

新数据满足各个指标的均值为0, 标准差为1

- 极差标准化:


$$x_{ij} = \frac{x_{ij} - \min_i \{x_{ij}\}}{\max_i \{x_{ij}\} - \min_i \{x_{ij}\}}$$

新数据满足各个指标的值域为 [0, 1]


聚类对象	要素					
	x_1	x_2	...	x_j	...	x_n
1	x_{11}	x_{12}	...	x_{1j}	...	x_{1n}
2	x_{21}	x_{22}	...	x_{2j}	...	x_{2n}
⋮	⋮	⋮		⋮		⋮
i	x_{i1}	x_{i2}	...	x_{ij}	...	x_{in}
⋮	⋮	⋮		⋮		⋮
m	x_{m1}	x_{m2}	...	x_{mj}	...	x_{mn}

对样本表格中的**每一列**进行标准化处理

聚类质量评估



较差的聚类结果



较优的聚类结果

衡量聚类结果的好坏，以类内最为相似，类间最不相似为标准。

聚类质量评估

考虑聚类结果中，样本被划分为 k 个类别 $\{C_1, C_2, \dots, C_k\}$ 。常用的评估指标有：

- 均方根误差（RMSE）：

$$RMSE = \frac{\sum_{i=1}^k s_i}{k}$$

其中， s_i 为类别 C_i 内样本与类别上的样本均值点上的距离标准差。

计算简单，但仅反映类别内的相似性，一般只在计算效率要求高时采用。

- DB指数（Davies-Bouldin Index, DBI）：

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left\{ \frac{avg(C_i) + avg(C_j)}{dist(\bar{C}_i, \bar{C}_j)} \right\}$$

其中， $avg(C)$ 为 C 类别内所有样本两两之间的平均相似度； $dist(\bar{C}_i, \bar{C}_j)$ 为类别 C_i 和 C_j 各自的样本均值点的相似度。DB指数最小为零，越小越好。

聚类分析基本过程

1. 选择描述事物本质属性的指标，去除无关指标
2. 确定样本是否需标准化，选择标准化方法
3. 选择样本相似度的度量（距离计算）方法
4. 选择和实施聚类算法
5. 结果分析和调整

聚类算法


聚类算法主要包含：

- **中心聚类**：用类别内样本的中心点(均值点、中位点等)表征不同类别，通过优化类别的中心点达到聚类目的，如**k-均值算法**、k-Medoids算法。
- **层次聚类**：认为一个样本和最邻近样本是属于同一类别，通过连接最邻近样本形成聚集的类别。
- **概率分布聚类**：通过不同统计分布描述聚集的不同类别，如混合高斯模型。
- **密度聚类**：将类别聚集定义为样本高密度区域，进而进行类别划分，常见算法有DBSCAN和OPTICS。

k-均值聚类

k-均值 (k-Means) 聚类的是一种迭代计算类别中心的聚类方法，先给个较粗糙的初始类别，然后修改类别均值点和样本类别，直到分类比较合理为止。

k-均值聚类认为**聚集的类别可用类别内样本的均值点（聚类中心点）**进行表征。




终止条件可以均值点不再变动、DBI降低到一定阈值或者达到最大迭代次数。

k-均值聚类

现有一份某疾病患者年龄和血氧含量样本，经过标准化后，如下表所示：


样本ID	年龄	血氧含量
1	0.134929	0.677336
2	0.188018	0.742313
3	0.261828	0.747854
4	0.225082	0.737381
5	0.222214	0.758585
6	0.106899	0.716197
7	0.211813	0.689538
...	...	



以年龄-血氧含量作二维空间的
患者样本分布



k-均值聚类

1. 输入类别个数 $k = 3$
2. 将样本随机分配到一个类别上
3. 计算每个类别的均值点
4. 将每个样本分配到最近的均值点对应的类别上
5. 重新计算每个类别的均值点
6. 重复4和5直到每个类别的均值点都不再变动为止（或达到最大迭代次数等）




k-均值聚类

- k -均值聚类方法需要输入所需的类别数 k 。
- 计算复杂度较低，但对异常样本 (离群样本) 非常敏感。
- 普通 k -均值聚类适用于特征空间中具有**成团特征**的样本（左下图），在复杂分布模式的样本上聚类效果不佳（右下图）。



层次聚类



自然划分的类别中可能存在层次结构



层次聚类 (Hierarchical Clustering) 是通过一系列的相继的类别合并或者类别分割来进行的。主要有两种形式：

- **聚集层次法**：从单个样本开始，对两两最相似的样本或类别，聚集为一个类别，直到最终只有一个类别；
- **分割层次法**：最初将所有样本作为一个类别，将其划分为两个类别，使得两个类别之间最不相似，直到每个样本单独为一个类别。


层次聚类

设有11个样本，每个样本有两个指标，采用**聚集层次法**中的**单连接层次法**对其进行聚类。


单连接层次法：每次对两两样本-样本间、样本-类别间和类别-类别间，选择样本距离或最邻近样本距离中最小的，进行聚合。



层次聚类




层次聚类结果中的几个类别



样本和类别间的结构联系图

- 层次聚类可以得到样本类别间**层次联系**，反映了不同相似水平上的聚类情况。
- 层次聚类不用预先指定类别数，在结果中选择足够满足分析的类别数即可。
- 层次聚类计算复杂度和空间复杂度很高，每次分割或聚合可能需要判断所有样本间的相似性。

聚类



聚类

聚类特点：

- 聚类无需样本集合的**先验知识**（如类别内部特征、类别合理数量等）；
- 聚类结果只是对相似样本进行划分，并不能得出类别具体的含义，需要后续分析确定；
- 在样本集中添加新数据后，原有的聚类结果会发生改变；
- 聚类有助于对样本集划分类别后，对数据进行组织，高效率地进行检索；



主要内容

- 聚类
- 分类



分类

绿色类别 {   }

蓝色类别 {   }

红色类别 {   }

有颜色类别的样本




无颜色类别标注的样本

可否基于现有的样本，利用计算机对其他样本信息进行属性的学习，从而达到识别样本信息所相应的类别？

分类

分类 (Classification): 基于已知样本类别集合, 学习决策规则, 对未知类别的样本, 进行类别划分。



- 根据已有的样本类别和类别的先验知识, 确定相应的分类模型, 其中利用已知类别的样本的信息, 求解待定分类模型参数的过程, 称为**训练(学习)过程**。
- 对训练好的分类模型, 输入未知类别的样本, 确定这些样本所属的类别, 称为**分类(预测)过程**。

分类和聚类

- 分类和聚类的结果中都对样本进行了类别划分。
- 聚类可视为分类的一种。
- 分类和聚类的区别：
 - 分类是将样本划分给已有的类别；聚类将相似样本划分为相同的类别
 - 分类需要类别的先验知识，而聚类不依赖样本的先验知识。
 - 聚类一般利用无类别标注的样本；分类主要利用有类别标注的样本，也有利用无类别标注的方法。

分类基本过程

- 1、确定感兴趣的类别
- 2、建立描述事物本质属性的指标体系
- 3、选择或标注训练样本集合
- 4、训练分类模型或判别函数
- 5、评估训练好的分类模型的分类精度
- 6、对非训练样本或新样本进行分类

分类

表：某疾病患者的病情发展程度样本

样本ID	年龄	血氧含量	病情发展
1	23	43.6	存活
2	14	84.2	存活
3	35	45.0	死亡
4	55	6.3	死亡
5	73	23.9	危重
6	60	7.2	危重
7	5	53.7	存活
...	...	...	

表：新患者的病情样本

样本ID	年龄	血氧含量	病情发展
1	45	64.3	-
2	34	51.2	-
3	35	12.5	-
4	12	4.6	-
5	96	45.7	-
...	...	...	

将病人病情发展类别作为感兴趣的类别，依靠已有某疾病患者年龄和血氧含量样本及其病情发展类别，对新患者的病情发展情况进行分类(预测)。


决策树模型

决策树 (Decision Tree) 模型是一种树形流
程式结构的模型：

- 分支节点表示对某一样本特征对类别的划分
- 叶节点表示判断的类别

决策树模型一般为二叉树形式；

决策树分类模型可以显式地表示出来决策过程。



某疾病患者的病情发展程度类别
决策树模型

决策树模型



基于已知样本，构建一个决策树模型的算法有ID3、C4.5和CART等。通常包含三个步骤：

1. **特征选择**：从样本的众多特征中，选择一个特征，作为当前节点的分裂标准
2. **新增节点**：根据划分准则和选择的特征，分裂决策树当前的节点。重复1和2，直到决策树无法生长。
3. **决策树剪枝**：决策树容易将过度划分样本特征和空间，使得决策树不适应新样本，需要去除一些分支。

决策树模型

生成决策树模型，主要依靠对样本特征的划分：

- 生成一个决策数的节点，可视为对样本的特征空间划分一次。
- **划分准则：**每次划分，都使得样本子集纯度要比划分之前的更高，如信息熵减少。



决策树模型

- 决策树模型的参数和分类过程易于解释，有助于对类别间差异的分析；
- 构建决策树模型，并不需要对样本集有任何的统计分布要求（如正态性）；
- 决策树模型对训练样本的敏感性很高，训练样本微小变动容易导致模型参数和分类结果精度发生较大变动；
- 非常容易**过拟合**（在训练样本上的分类准确度高，但对其他样本分类准确度低），需要结合剪枝策略；

分类模型评估

- 分类模型并不能保证对每个样本都能划分到相应所属的类别之中。
- 判断分类模型效果的重要途径，就是计算其分类的**准确度或错分概率**等指标。

为了在分类模型训练完毕后，对分类模型效果进行评估，一般在训练前，将已知类别的样本集合划分为**训练集和测试集**：

- **训练集**用于训练分类模型；
- 用训好的分类模型分类**测试集**样本，比较分类结果和已知测试样本类别，计算评估指标。

分类模型评估

通过训练后的分类模型，对测试样本分类，可得到测试样本的分类结果，通过与真实值进行比较，可统计得到如下表格，称之为**混淆矩阵**。

表：某疾病患者病情发展程度类别决策树模型分类结果**混淆矩阵**

真实类别 模型分类	存活	死亡	危重	Total
存活	239	21	16	276
死亡	16	73	4	93
危重	6	9	280	295
Total	261	103	300	664

通过混淆矩阵，可以计算**总体分类精度**，即正确分类样本数量 n_{correct} 除以总测试样本数量 N ：

$$P_o = \frac{n_{\text{correct}}}{N} = \frac{239 + 73 + 280}{664} = 89.2\%$$

分类模型评估

- 总体分类精度 P_o ，可以大致反映出分类模型的准确度，但无法反映样本类别本身差异带来的施测可信度。

假设上述患者样本集合中，患病者99%为存活，而死亡和危重都仅为0.5%。

如果分类模型只是简单地把样本都归为存活类别，则其**总体分类精度高达99%**。

但此时分类模型对于识别病情发展类别是无用的。

分类模型评估

- 对分类结果进行具有鲁棒性的评估，可通过混淆矩阵计算**Kappa系数**：

$$k = \frac{p_o - p_e}{1 - p_e}$$

其中， p_o 为总体分类精度； $p_e = \frac{\sum_i^r n_i * n'_i}{N^2}$ 为偶然一致性的样本比例； n_i 和 n'_i 分别为类别 i 在测试样本和模型分类结果的数量。

Kappa系数值处于 $[-1, 1]$ 区间内：

- 接近于 1，说明模型分类结果和样本真实类别越一致；
- 接近于 0，说明分类结果可能是偶然造成的；
- 接近于-1，说明分类结果和真实类别很不一致；

监督分类与非监督分类


- **监督分类**是已知部分样本所属类别，以及这些类别的**先验知识**，对分类模型参数进行学习，达到“有目的”的分类。如决策树模型和朴素贝叶斯模型的构建和使用。
- **非监督分类**是指人们事先**不对分类过程施加任何的先验知识**，仅凭数据的特征的分布规律，即自然聚类的特性进行“盲目”的分类。一般认为非监督分类就是**聚类**；

监督分类与非监督分类

- 监督分类必须在分类前收集或圈定样本各个类别性质单一的训练集合;
- 监督分类是先学习后分类;
- 非监督学习是边学习边分类;
- 非监督分类的结果只是对不同类别达到了区分, 并不能确定类别的属性或实际意义, 需要后续分析确定。



Weka 分类实验

https://waikato.github.io/weka-wiki/downloading_weka/



Weka 分类实验

https://waikato.github.io/weka-wiki/downloading_weka/

weka.gui.GenericObjectEditor
weka.clusterers.SimpleKMeans



About
Cluster data using the k means algorithm. [More](#)
[Capabilities](#)

canopyMaxNumCanopiesToHoldInMemory 100
canopyMinimumCanopyDensity 2.0
canopyPeriodicPruningRate 10000
canopyT1 -1.25
canopyT2 -1.0
debug False
displayStdDevs False
distanceFunction Choose **EuclideanDistance**
doNotCheckCapabilities False
dontReplaceMissingValues False
fastDistanceCalc False
initializationMethod Random
maxIterations 1000
numClusters 5
numExecutionSlots 1
preserveInstancesOrder False
reduceNumberOfDistanceCalcsViaCanopies False
seed 10

Open... Save... OK Cancel

Weka 分类实验

https://waikato.github.io/weka-wiki/downloading_weka/

weka.gui.GenericObjectEditor
weka.clusterers.SimpleKMeans

About
Cluster data using the k means algorithm. [More](#)
[Capabilities](#)

canopyMaxNumCanopiesToHoldInMemory 100

canopyMinimumCanopyDensity 2.0

canopyPeriodicPruningRate 10000

canopyT1 -1.25

canopyT2 -1.0

debug False

displayStdDevs False

distanceFunction [Choose](#) EuclideanDistance

doNotCheckCapabilities False

dontReplaceMissingValues False

fastDistanceCalc False

initializationMethod Random

maxIterations 1000

numClusters 5

numExecutionSlots 1

preserveInstancesOrder False


reduceNumberOfDistanceCalcsViaCanopies False

seed 10

[Open...](#) [Save...](#) [OK](#) [Cancel](#)

Weka 分类实验

https://waikato.github.io/weka-wiki/downloading_weka/



Weka Explorer

Preprocess Classify **Cluster** Associate Select attributes Visualize

Clusterer
Choose **SimpleKMeans** -init 0 -max-candidates 100 -periodic-pruning 10000 -min-density 2.0 -t1 -1.25 -t2 -1.0 -N 5 -A "weka.core.EuclideanDistance" -R first-last" -I 100

Cluster mode
☐ Use training set
☐ Supplied test set Set...
☐ Percentage split % 66
☒ Classes to clusters evaluation
 (Nom) class
☒ Store clusters for visualization
 Ignore attributes
 Start Stop

Result list (right-click for options)

- 08:41:27 - SimpleKMeans
- 08:42:08 - SimpleKMeans
- 08:43:30 - SimpleKMeans
- 08:45:27 - SimpleKMeans
- 08:45:40 - SimpleKMeans
- 08:48:19 - HierarchicalClusterer
- 09:02:17 - SimpleKMeans**

Clusterer output

kMeans
=====

Number of iterations: 22
Within cluster sum of squared errors: 87.18451953431818

Initial starting points (random):

Cluster 0: 1,126,56,29,152,28.7,0.801,21
Cluster 1: 8,95,72,0,0,36.8,0.485,57
Cluster 2: 1,97,66,15,140,23.2,0.487,22
Cluster 3: 2,112,68,22,94,34.1,0.315,26
Cluster 4: 14,100,78,25,184,36.6,0.412,46

Missing values globally replaced with mean/mode

Final cluster centroids:

Attribute	Full Data (768.0)	Cluster# 0 (159.0)	1 (137.0)	2 (35.0)	3 (309.0)	4 (128.0)
preg	3.8451	1.9119	6.2263	3.2857	1.9903	8.3281
plas	120.8945	144.5912	130.4745	116.6571	101.0097	130.3672
pres	69.1055	73.6164	77.7226	0.6857	67.6537	76.4922
skin	20.5365	34.0063	1	1.2	19.479	32.5547
insu	79.7995	196.5094	4.3139	0.7143	47.4563	115.3203
mass	31.9926	36.7742	30.9482	25.36	29.8521	34.1516
pedi	0.4719	0.6284	0.3805	0.3881	0.4172	0.5301
age	33.2409	29.1635	44.927	30.0571	25.5016	45.3516

Status
OK Log x 0



谢谢!

