



空间统计与分析

Spatial Statistics and Analysis

涂 伟

深圳大学城市空间信息工程系

2026年春



第四章 回归分析与空间回归分析

Regression and Spatial Regression

主要内容

- 回归分析
- 空间自回归
- 地理加权回归

主要内容

- 回归分析
- 空间自回归
- 地理加权回归

主要内容

- 回归分析
- 空间自回归
- 地理加权回归

回归分析


Figure 10




回归分析

回归现象：

- 英国生物学家高尔顿和皮尔逊，分别在遗传学中发现，生物后代的属性与其父母有关。
- 高个子的子女平均高度较高，矮个子的子女平均高度较低。
- 但是，发现高个子的子女的平均高度比父代低，而矮个子的子女的平均高度要比父代高
- 不可能代代都增高，或代代变矮。后代的高度有向平均高度回归的趋势，离开均值越远，受到回归的压力越大。“回归（Regression）”这个词就由此而来。



F. Galton




K. Pearson



回归分析

相关分析的不足：


- 没有模型或公式表达描述变量间的关系
- 不能对未知样本预测其观测值




回归分析

回归分析：对于存在相关的两个或多个变量，将其中一个或多个作为**自变量**，另一个作为**因变量**，并将**自变量和因变量的相关关系用数学方程式表示**，则可利用该方程由自变量来估计、预测因变量的值。

回归分析建立起的方程称为**回归模型（方程）**。



回归分析



回归分析

回归分析与相关分析

- 相关关系的两个变量同时都是随机变量；回归分析中，区分自变量 X 和因变量 Y ，因变量为随机变量，假定自变量是非随机的可控变量。
- 相关分析中，**相关系数反映两个变量的密切程度，但不能给出二者具体的数量变化关系**；回归分析建立了二者的数量变化关系回归方程，**可定量揭示自变量对因变量的影响，还可对因变量值进行预测**。
- 相关分析可作为回归分析的基础：相关分析需回归分析来表明现象数量关系的具体形式，而回归分析则应建立在相关分析基础上。

回归分析

回归分析的需要回答的基本问题：

- 自变量和因变量是否相关？
- 如何求得其回归模型？
- 怎样评价回归模型的拟合效果？
- 如果用来预测，怎样评价预测结果？


线性回归模型

对于 p 个自变量的线性回归模型的一般形式：

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p + \varepsilon$$

其中，

- y 为因变量；
- $x_1, x_2, \dots, x_p$ 为自变量；
- $b_1, b_2, \dots, b_p$ 为线性回归模型回归系数；
- ε 表示误差项，是一个随机变量，无法用 X 解释



一元线性回归

- 一元线性回归模型：即二维平面下的直线方程，可表示为：

$$y = b_0 + b_1x + \varepsilon$$

其中

- b_0 和 b_1 为待求解的未知参数；
- ε 表示误差项；

- 由于样本总体和随机误差都未知，无法获得上述方程参数。因此，我们转而想获得一个**能够最大程度拟合样本线性关系**的方程，为了区分常表示为：

$$\hat{y} = \hat{b}_0 + \hat{b}_1x$$


其中：

- $\hat{y}$ 为因变量拟合值，也称为预测值。
- $\hat{b}_0$ 和 $\hat{b}_1$ 分别为参数 b_0 和 b_1 的拟合值；

一元线性回归

线性回归的基本假设条件：

- 自变量 X 和因变量 Y 之间具有**线性关系**：线性回归分析最基本假设和分析的前提。
- 与一个 x 值对应的一组 y 值，构成 Y 的一个子总体，所有这样的子总体都服从正态分布，如下图所示：




- 与一个 x 值对应的一组 y 值与另一个 x 值对应一组 y 值之间没有关系，彼此独立。

一元线性回归

一元线性回归系数几何意义

$$\hat{y} = \hat{b}_0 + \hat{b}_1 x$$

- $\hat{b}_0$: 截距, 自变量 x 为0时 y 的估计值
 - $\hat{b}_0 > 0$: 回归线与纵轴交点在原点上方。
 - $\hat{b}_0 < 0$: 回归线与纵轴交点在原点下方。
 - $\hat{b}_0 = 0$: 回归线通过原点。
- $\hat{b}_1$: 回归直线斜率, 表明自变量 x 变化一个单位时应变量 y 的平均改变量。



一元线性回归——参数求解

一元线性回归方程**参数求解**:

- 构造某种标准评价拟合方程的效果, 如观测值和拟合值的**偏差(残差)** $y_i - \hat{y}_i$
为消除偏差正负符号的影响, 一般采用全部样本的观测值 y_i 与其回归方程预测值的**偏差平方和** (SSE , 残差平方和)表示:

$$Q(b_0, b_1) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- 可采用**最小二乘法** (Least Squares Method, LSM) 求解, 即寻找参数 $\hat{b}_0$ 和 $\hat{b}_1$ 使得偏差平方和 SSE 最小。

一元线性回归——参数求解

- 最小二乘法使 $Q(b_0, b_1)$ 值最小问题，实际上是一个求极值问题。
- 根据微积分原理，分别求偏导数且使其等于0：

$$\begin{aligned} \frac{\partial [\sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2]}{\partial b_0} &= 0 \\ \frac{\partial [\sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2]}{\partial b_1} &= 0 \end{aligned} \quad \begin{array}{c} \longrightarrow \\ \text{推导得} \end{array} \quad \begin{aligned} \hat{b}_1 &= \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} (\sum_{i=1}^n x_i) (\sum_{i=1}^n y_i)}{\sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}} \\ \hat{b}_0 &= \bar{y} - \hat{b}_1 \bar{x} \end{aligned}$$

也可以采用**最大似然估计法**(Maximum Likelihood, ML)求解模型参数

回归模型检验

通过对偏差平方和的公式进行变换，可得到 y 的 n 次观测值之间的差异：


$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

简写为： $SST = SSE + SSR$

称之为： 总平方和 残差平方和 回归平方和

自由度： $n-1$ $n-2$ 1

回归模型检验



- 总平方和(SST) : 代表样本中因变量值 y 的变动情况
- 残差平方和(SSE) : 代表回归方程值 $\hat{y}$ 没有观测到的变动, 越大说明拟合效果越差
- 回归平方和(SSR) : 代表回归方程值 $\hat{y}$ 观测到的变动, 越大说明拟合效果越好


回归模型检验

1. 回归方程的拟合优度检验：检验线性回归方程对样本观测值的拟合程度，常用**决定系数（判定系数）** R^2 ：

$$R^2 = \frac{SSR}{SST}$$


决定系数 R^2 表明了自变量 X 能够对因变量 Y 的变动解释的比率：

- R^2 的取值在 $[0, 1]$ 之间；
- R^2 越接近 1，表明拟合效果越好；
- R^2 越接近 0，表明拟合效果越差；



$R^2 = 0.796$ ，说明土壤侵蚀的产生变化可由降雨变化解释 79.6%

回归模型检验



$R^2=0.796$, 说明土壤侵蚀的产生变化可由降雨变化解释79.6%

降雨量每增加1mm, 相应地, 侵蚀量增加 0.9269

回归模型检验

2. 回归方程显著性检验： R^2 没有考虑到样本容量，因此不是严格的显著性检验方法。检验自变量 x 对因变量 y 是否具有明显影响可采用F检验。

$$F = \frac{SSR}{SSE/(n-2)} = (n-2) \frac{R^2}{1-R^2} \sim F(1, n-2)$$

原假设一般为： $H_0: b_1 = 0$ ，即两个变量之间无线性相关关系。

- 当 $F > F_\alpha$ 时，拒绝 H_0 ，表明总变异中回归平方贡献显著，回归方程显著
 - 否则，说明回归方程不显著。
- 上述方法称之为一元回归的方差分析

回归模型检验

3. 回归系数的检验：检验自变量 x 对因变量 y 是否具有明显影响也可采用 t 检验，即直接检验参数 b 是否显著不等于0.

$$t = \frac{b_1}{\sqrt{\frac{1}{n-2} \cdot SSE \cdot \sum_{i=1}^n (x_i - \bar{x})}} \sim t(n-2)$$

- 一元线性回归方程下，该检验的原假设与结论和F检验相同。
- 在多元线性回归的参数检验下，只需要对不同自变量 x 对应的回归参数 b 构建 t 检验，即可检验对应自变量对因变量是否具有显著影响


多元线性回归模型

对于 p 个因变量的多元线性回归模型:

$$y = b_0 + \sum_{j=1}^p b_j x_j + \varepsilon$$

其中,

- $b_0, b_1, \dots, b_p$ 称为偏回归系数
- b_j 为自变量 x_j 的回归系数,
- b_j 描述了当其他自变量都固定时, 自变量 x_i 每变化一单位而使得因变量平均改变的数值。



多元回归分析中, 常称回归函数为回归曲面, 或者响应曲面

多元线性回归模型

- 经典多元线性回归模型的基本假设：
 - 所有的自变量之间相互独立（无多重共线性）
 - 随机扰动项 ε ，具有零期望、同方差序列不相关
 - 自变量和随机扰动项不相关
 - 随机扰动项满足均值为零的正态分布
- 多元线性回归模型的参数估计方法：
 - 普通最小二乘法
 - 极大似然估计
 - 矩估计

非线性回归

非线性回归模型可划分为：

- **内线性回归模型：** 参数不是线性， 但经变换可使得参数化为线性形式， 如：

$$Y_i = \gamma_0 \exp(\gamma_1 X_i) \varepsilon_i \quad \Rightarrow \quad \ln Y_i = \ln \gamma_0 + \gamma_1 X_i + \ln \varepsilon_i$$

- **非线性回归模型(狭义)：** 的模型参数是非线性的， 且不能通过变换转为线性形式， 如：

$$Y_i = \gamma_0 \exp(\gamma_1 X_i) + \varepsilon_i$$


主要内容

- 回归分析
- 空间自回归
- 地理加权回归

空间依赖

空间上相邻的地理单元可能存在**空间依赖**。

- 东京某地的劳动年龄内死亡人数的上升，可能会影响周边地区的相应死亡人数。虽然无因果关系，但可能有无法观测的因素是空间相关的（例如核辐射）。
- **空间依赖**反映的是一个区域某种地理现象或空间实体属性值与邻近区域同一地理现象或空间实体属性值的相关程度。



东京各地劳动年龄内死亡人数

空间自回归

意大利的新冠肺炎患病率可能会很容易影响英国和法国的新冠患病率。但韩国的患病率却很难受到意大利的影响，因为在地理空间太遥远了。

- 空间单元间存在一定的相互关系，而且距离越近产生这种关系的可能性就越强。
- **空间依赖**产生于直接邻接的空间实体间，也随着时间的推移扩散到邻近的区域，继而扩散至更多的空间单元。这种由邻域向邻域扩散的空间效应，可以由“**空间滞后**”的角度来理解。
- **空间滞后**反映了相邻的空间单元因变量取值的相似性。

空间自回归

空间滞后反映了相邻的空间单元因变量取值的相似性，数学表达为：

$$y^* = Wy$$

其中， y 为 n 个空间单元上的因变量值； y^* 为受相邻空间单元因变量影响后的因变量取值。 W 为空间权重矩阵。

空间权重矩阵 W （也称空间滞后算子）意味着空间上的推移，通过空间滞后算子可以得出实际上相邻的空间单元观测值依距离加权的平均值。


$$W = \begin{bmatrix} 0 & w_{12} & \cdots & w_{1n} \\ w_{21} & 0 & \cdots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & \cdots & 0 \end{bmatrix}$$

w_{ij} 描述了两个空间单元在空间上的邻近程度，可以是邻接性，也可以是根据空间距离计算的权重

空间自回归

- 空间依赖意味着空间上的观测值之间不是相互独立的，所以典型的线性回归模型由于其严格的假设条件（如变量独立等），无法将空间相关性考虑进去。
- 当典型线性回归模型的残差可以被自变量和因变量的空间分布所描述时（如右图，模型残差的空间自相关指数较高），可考虑采用空间自回归。
- 空间自回归模型（Spatial Autoregression, SAR）
可以将空间相关的因变量和空间相关的误差项考虑进去。

空间依赖下线性回归模型残差空间分布



残差的高值和低值出现空间聚集

空间自回归

- 对回归模型（如线性回归模型）的残差计算空间自相关指数，如
 - 全局Moran's I
 - 全局Geary's C
- 采用空间自相关指数可判断回归残差是否在空间上随机分布。
- 高残差和/或低残差（模型偏高预计值和偏低预计值）在空间上的显著聚类表明模型中的某个关键变量缺失了。
- Geary's $C \geq 0.2$ 时一般说明残差存在较为明显的空间高低聚集。

空间自回归

空间自回归：通过在构建模型时显式地引入空间滞后变量，可以估算和检验空间自相关对空间关联的贡献。

空间自回归模型的一般形式：

$$Y = \rho W_1 Y + X\beta + u$$

$$u = \lambda W_2 u + \varepsilon$$

- Y 是因变量； X 是解释变量；
- β 表示自变量的回归系数；
- u 是空间相关的误差项；
- W_1 是反映因变量空间趋势的空间权重矩阵；
- W_2 为反映残差空间趋势的空间权重矩阵。

空间自回归

$$Y = \rho W_1 Y + X\beta + u \quad u = \lambda W_2 \mu + \varepsilon$$

↑
空间滞后因子
↑
空间相关误差

一般形式的空间自回归模型可以派生出其他几种模型：

- 当 $\rho = 0$, $\lambda = 0$ 时，即不考虑空间相关项，模型为普通线性回归模型。
- 当 $\rho \neq 0$, $\beta = \lambda = 0$ 时，仅仅考虑空间滞后，为一阶空间自回归模型。
- 当 $\rho \neq 0$, $\beta \neq 0$, $\lambda = 0$ 时，考虑空间滞后因子，为空间滞后模型。
- 当 $\rho = 0$, $\beta \neq 0$, $\lambda \neq 0$ 时，考虑空间相关误差，为空间误差模型。
- 当 $\rho \neq 0$, $\beta \neq 0$, $\lambda \neq 0$ 时，为空间杜宾模型。

空间自回归——空间滞后模型

空间滞后模型（混合回归与空间自回归模型）认为相邻研究区域间的因变量存在空间自相关性，在模型中引入空间滞后因子 WY 作为自变量。

模型中空间单元上的因变量 Y 与本单元的自变量 X 有关，也和邻近空间单元上的因变量 Y 有关，公式为：

$$Y = \rho W_1 Y + X\beta + \varepsilon$$

$$\varepsilon \sim N[0, \sigma^2 I]$$

其中：

- ρ 表示空间滞后项的系数，取值 $[0, 1]$ ，越接近1，表示相邻地区的因变量取值越相似。
- ε 是服从独立同分布的正态分布 N 维随机向量。

空间自回归——空间滞后模型

- 空间滞后模型在普通线性回归的基础上整合了空间滞后因子。
- 空间滞后模型可将**因变量Y的空间相关性考虑**在内，以避免仅采用空间单元内自变量X导致无法有效估计和预测因变量Y的变化趋势。

空间自回归——空间误差模型

空间误差模型（空间残差自回归模型）中，因变量不存在空间自相关性，但是自变量存在空间自相关性。

空间单元上的因变量Y和本单元自变量X有关，也受到相邻单元的误差 ε 的影响，公式：

$$Y = X\beta + \mu$$
$$\mu = \lambda W_2 \mu + \varepsilon$$

其中：

- λ 表示空间误差系数，取值 $[0, 1]$ ，越接近1，表示相邻地区的自变量取值越相似
- μ 是服从独立同分布的正态分布N维随机向量。
- $\varepsilon \sim N[0, \sigma^2 I]$

空间自回归——空间杜宾模型

空间杜宾模型通过加入空间滞后变量增强空间自回归模型。

空间单元上的因变量Y不仅和本单元自变量X有关，也和相邻单元的因变量Y和自变量X有关，公式：

$$Y = \rho WY + X\beta + W\bar{X}\gamma + \varepsilon$$

其中：

- $\bar{X}$ 为一个可变的自变量矩阵；
- γ 为参数向量，用于度量相邻区域的自变量对因变量的边际影响

空间自回归——参数估计与残差

- 空间滞后模型、空间误差模型和空间杜宾模型的参数一般无法采用普通最小二乘法得出，可采用**最大似然估计**或者**广义矩估计**。

例如，对于空间滞后模型，可获得模型参数估计值 $\hat{\rho}$ 和 $\hat{\beta}$
最终可以计算出空间滞后模型的残差 e ，如下：

$$e = Y - \hat{\rho}W_1Y + X\hat{\beta}$$

- 可绘制出残差的空间分布
- 利用残差、模型预测值和因变量观测值计算出拟合优度 R^2

空间自回归——空间回归模型检验

经过参数估计后得到的空间自回归模型，进行检验主要是基于**拉格朗日乘数**（Lagrange Multiplier, LM）检验回归模型的约束是否有效，LM服从卡方分布。包含两方面检验：

- **残差空间相关性**：检验**空间残差**是否具有空间自相关特性
- **空间自回归效应**：检验**因变量**是否具有空间自相关特性

空间自回归——空间回归模型检验

1. 不存在空间自回归时空残差相关的LM检验 (LM-error)

原假设: $H_0: Y = X\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma^2 I_n)$

构造的检验统计量:

多元线性回归

$$LM = \frac{(e'We/s^2)^2}{T} \sim \chi^2(1)$$

2. 存在空间自回归时空残差相关的LM检验 (Robust LM-error)

原假设: $H_0: Y = \rho WY + X\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma^2 I_n)$

构造的检验统计量:

空间滞后模型

$$LM = \frac{[e'We/s^2 - T(R\tilde{J})^{-1}(e'WY/s^2)]^2}{T - T^2(R\tilde{J})^{-1}}$$

空间自回归——空间回归模型检验

3.不存在空间残差相关时空间自回归效应相关的LM检验 (LM-lag)

原假设: $H_0 : Y = X\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma^2 I_n)$

构造的检验统计量:

空间误差模型

$$LM = \frac{(e'We / s^2)^2}{R\hat{J}} \sim \chi^2(1)$$

4.存在空间残差相关时空间自回归效应相关的LM检验 (Robust LM-lag)

原假设: $H_0 : Y = X\beta + \lambda W\varepsilon + \mu \quad \varepsilon \sim N(0, \sigma^2 I_n)$

构造的检验统计量:

空间误差模型

$$LM = \frac{(e'WY / s^2 - e'We / s')^2}{R\hat{J} - T} \sim \chi^2(1)$$

空间自回归——空间回归模型检验

上述LM检验可总结出：


- 残差空间相关性：原假设可设定为 $\lambda = 0$
 - 空间误差模型上如果原假设成立，说明应去除空间误差项（ $\lambda W_2 \mu$ ）变为线性回归模型可能会取得更好回归效果
 - 空间滞后模型上如果原假设不成立，说明应增加空间误差项（ $\lambda W_2 \mu$ ）变为一般空间自回归形式（空间滞后-残差自回归模型）
- 空间自回归效应：原假设可设定为 $\rho = 0$
 - 空间误差模型上如果原假设不成立，说明应增加空间滞后因子（ $W_1 Y$ ）变为一般空间自回归形式
 - 空间滞后模型上如果原假设成立，说明应去除空间滞后因子（ $W_1 Y$ ）变为线性回归模型

空间自回归——空间回归模型选择


为了从空间滞后模型和空间误差模型中选出最具客观实际意义的，可采用上述检验中的LM乘数统计量进行判断：

- 首先用构建线性回归 $Y = X\beta + \varepsilon$ (OLS回归)，计算出空间残差等
- 计算LM乘数统计量，采用右方流程图进行判断

OLS: Ordinary Linear Regression



空间自回归——案例



空间相关的因变量：室内极端案件 (Y)

空间自回归

1. 采用线性回归模型($Y = b_0 + b_1x_1 + b_2x_2 + b_3x_3 + \dots + \varepsilon$)进行拟合(OLS回归), 检验其拟合效果和残差空间自相关性, 并计算LM指数

决定系数 $R^2 = 0.103657$

残差 $Moran's I = 8.3495$

表: LM统计量结果

统计量	Value	P-Value	
LM-lag	80.3495	<0.0001	} 显著
Robust LM-lag	19.0122	<0.0001	
LM-error	66.4285	<0.0001	
Robust LM-error	5.1188	0.02367	不显著

2. 因此, 采用空间滞后模型 ($Y = \rho Wy + X\beta + \varepsilon$)

决定系数 $R^2 = 0.158910$

残差 $Moran's I = -0.022$


主要内容

- 回归分析
- 空间自回归
- 地理加权回归

地理加权回归

空间异质性

- 各种事物和现象在空间上缺乏平稳的结构
- 空间单元本身不是均质的，在面积和形状上具有较大差别



空间非平稳性

地理加权回归 (geographical weighted regression, GWR) 提出的背景和意义

- 在空间分析中，变量的观测值一般是以地理单位为抽样单位得到的，**随着地理位置的变化，变量间的关系或者结构会发生变化**，这种因地理位置的变化而引起的变量间关系或结构的变化称之为**空间非平稳性**。
- 全局模型在分析之前就假定了变量间的关系具有同质性，从而**掩盖了变量间关系的局部特性，所得结果只有研究区域内的某种“平均”**。

地理加权回归——基本模型

空间滞后模型、空间误差模型和空间杜宾回归模型都是**全局空间回归模型**，模型中的常数和各种影响因素的系数在不同空间单元上都是相同的。

地理加权回归——基本模型

地理加权回归模型是对普通线性回归模型的扩展，将数据的地理位置嵌入到回归参数中，即：

$$y_i = \beta_0(u_i, v_i) + \sum_{k=1}^p \beta_k(u_i, v_i) x_{ik} + \varepsilon_i$$

- (u_i, v_i) 是第 i 个采样点坐标；
- $\beta_k(u_i, v_i)$ 是第 i 个采样点上第 k 个回归参数，是地理位置的函数。
- ε_i 是第 i 个区域的随机误差。

如果 $\beta_{1k} = \beta_{2k} = \dots = \beta_{nk}$ ，则上述地理加权回归模型即为普通线性回归模型

OLS 模型

$$Y = X\beta + \varepsilon$$

地理加权回归——参数估计

- 地理加权回归模型中的回归参数在每个数据采样点上都是不同的，未知参数的个数远大于观测个数。
- 假设回归参数为一连续表面，位置邻近的回归参数相似，采用一个位置及其邻近位置上的观测值构成局部样本子集构建全局线性回归模型，估计一个位置上的回归参数。

地理加权回归的局部性

地理加权回归——参数估计

对于第*i*采样点的局部样本子集，可利用加权最小二乘法（Weighted Least Square, WLS）来估计参数，第*i*个采样点的回归参数($\beta_{i0}, \beta_{i1}, \dots, \beta_{ip}$)可通过使如下的式子达到最小来进行估计：

$$\sum_{j=1}^n w_{ij} (y_j - \beta_{i0} - \sum_{k=1}^p \beta_{ik} x_{ik})$$

其中， w_{ij} 是空间权重，所构成的对角矩阵 W 称为空间权重矩阵：


$$W = \begin{bmatrix} w_{i1} & 0 & \dots & 0 \\ 0 & w_{i2} & & 0 \\ & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & w_{in} \end{bmatrix}$$

还有哪些指标使用了空间权重矩阵？


描述了采样点*i*与其他*n* - 1个观测点间的空间关系。

地理加权回归——空间权函数

- 地理加权回归模型的核心是空间权重矩阵，它是通过选取不同的空间权函数来表达对数据空间关系的不同认识。
- 空间权重是由空间权函数确定，一般是关于距离的递减的。




利用空间权函数计算到邻近数据点的空间权重



带宽 (Bandwidth) 是用于描述空间权重与距离之间函数的非负衰减参数，越大表示权重随距离衰减越慢。


地理加权回归——空间权函数

全局函数 (Global)




$$w_{ij} = 1$$

指数型 (Exponential)



$$w_{ij} = e^{\left(-\frac{|d_{ij}|}{b}\right)}$$


距离阈值函数 (Box-Car)



$$w_{ij} = \begin{cases} 1 & d_{ij} \leq b \\ 0 & d_{ij} > b \end{cases}$$


地理加权回归——空间权函数

双重平方 (Bi-square)




$$w_{ij} = \begin{cases} (1 - (\frac{d_{ij}}{b})^2)^2 & |d_{ij}| < b \\ 0 & |d_{ij}| \geq b \end{cases}$$

三次立方 (Tri-cube)



$$w_{ij} = \begin{cases} (1 - (\frac{d_{ij}}{b})^3)^3 & |d_{ij}| < b \\ 0 & |d_{ij}| \geq b \end{cases}$$

高斯型 (Gaussian)



$$w_{ij} = e^{-\frac{d_{ij}^2}{b}}$$

地理加权回归——空间权函数

- 空间权函数的正确选取对地理加权回归模型参数的正确估计非常重要。
- 权函数的带宽选择影响了地理加权回归的效果
 - 带宽选择过大会导致参数估计的偏差过大
 - 带宽选择过小会导致参数估计的方差过大

地理加权回归——空间权函数

- 固定的最优带宽选择比较适用于空间单元数据均匀分布的情况
- 如果空间单元分布不均，某些回归点邻近区域没有数据，则导致回归参数估计方差太大，精度降低
- 可采用**自适应空间权函数**，根据数据在空间上的稀疏程度，选择不同带宽

常见的自适应空间权函数

核函数名称	
高斯型(Gaussian)	$w_{ij} = e^{-\left(\frac{d_{ij}}{b_{i(k)}}\right)^2}$
双重平方(Bi-square)	$w_{ij} = \begin{cases} \left(1 - \left(\frac{d_{ij}}{b_{i(k)}}\right)^2\right)^2 & d_{ij} < b_{i(k)} \\ 0 & d_{ij} \geq b_{i(k)} \end{cases}$

其中 $b_i(k)$ 是第 i 个数据点取周边最邻近的 k 个空间数据单元。

地理加权回归——假设检验

1. 回归模型的空间非平稳性检验——利用残差平方和检验地理加权回归模型优于普通线性回归模型的显著性检验

H_0 : 地理加权回归模型 $\hat{y}_S = Sy$ 的拟合优度与线性回归模型 $\hat{y}_H = Hy$ 的无明显差异;

$$\text{检验统计量: } F_1 = \frac{SSE_H}{SSE_S} \quad \text{或} \quad F_2 = \frac{SSE_H - SSE_S}{SSE_S}$$

2. 回归参数的空间非平稳性检验——判断因变量和自变量之间是否存在明显的空间非平稳性

$$H_0: \beta_{1k} = \beta_{2k} = \dots = \beta_{nk}$$

$$\text{检验统计量: } V_k^2 = \frac{1}{n} \sum_{i=1}^n (\hat{\beta}_{ik} - \frac{1}{n} \sum_{i=1}^n \hat{\beta}_{ik})^2$$

混合地理加权回归模型


- 有时候会发现并不是所有回归参数都是随着地理位置的变化而发生变化
- **混合地理加权回归模型**中让回归模型中的一部分回归参数随地理位置而变，称为变参数，而其余回归参数为常数，称为常参数

$$y_i = \beta_0 + \sum_{k=1}^q \beta_k x_{ik} + \sum_{k=1}^p \beta_k(u_i, v_i) x_{ik} + \varepsilon_i$$

其中：

- β_k 为常数参数，不随地理位置改变，去掉则该模型变为地理加权回归模型
- $\beta_k(u_i, v_i)$ 为第*i*个采样点坐标上的回归参数，去掉则该模型变为普通线性回归模型
- 改模型即混合了线性回归模型和地理加权模型

地理加权回归——案例1



实验数据

美国本土的506个经济发展区

膀胱癌死亡率数据 (Y): 国际癌症研究所Atlas癌症死亡率, 1970-1994年, 年龄标准化死亡率

肺癌死亡率 (x_1): 1954-1969年, 年龄标准化死亡率数局

人口密度 (x_2): 取每年人口密度的自然对数

地理加权回归——案例1

令因变量为膀胱癌死亡率 y ，自变量为肺癌死亡率 x_1 和人口密度自然对数 x_2

1. 普通线性回归模型：

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$

普通线性回归模型结果：

决定系数 $R^2 = 0.25$

回归系数估计结果

回归系数	Value	P-Value
β_0	80.3495	<0.0001
β_1	19.0122	<0.0001
β_2	66.4285	<0.0001

} 显著

表明膀胱癌死亡率，与肺癌死亡率和人口密度呈现明显正相关


地理加权回归——案例1

2. GWR 模型:

$$y_i = \beta_0(i) + \beta_1(i)x_1(i) + \beta_2(i)x_2(i) + \varepsilon_i$$

GWR 模型结果:

- 通过VC交叉验证, 取最优高斯型空间权函数的波段宽度为1.27。
- 决定系数 $R^2 = 0.52$, 提高了拟合精度。



各回归系数的频度分布

估计的系数展现出一种明显的变化, 在一些地区出现了违反直觉的**负相关**关系, 肺癌和人口密度都是, 而且人口密度的负相关更加明显。

地理加权回归——案例1




$\beta_1(i)$ 肺癌发生率回归系数空间分布



$\beta_2(i)$ 人口密度回归系数空间分布

- 深色区域表明了这些区域肺癌和人口密度，与膀胱癌有较为强的正相关；
- 浅色区域表明了与膀胱癌呈现了一定负相关；
- 回归系数呈现了一定的高低值空间聚集

地理加权回归——案例2



佐治亚州拥有学士学位的人口比例分布

佐治亚州人口普查数据字段

各县的普查数据

- 1990年各县的人口
- 各县的农村人口比例
- 各县拥有学士学位的人口比例
- 各县65岁及以上的人口比例
- 各县在国外出生的人口
- 各县生活在贫困线以下的人口
- 各县的非裔人口


利用佐治亚州人口普查数据 (X) 拟合各县拥有学士学位人口比例 (Y)

地理加权回归——案例2


1. 普通线性回归结果: $R^2 = 0.24$

2. GWR 结果: $R^2 = 0.30$


- 采用高斯核函数构建空间权重矩阵, 使用AIC准则选取最优带宽49.46
- 说明地理加权回归模型较普通最小二乘回归模型显示出更好的拟合优度



农村人口加权回归系数



贫困人口加权回归系数




非裔人口加权回归系数

地理加权回归模型能够更大限度地挖掘和展示空间异质性

谢谢！

空间回归实验

空间自回归实验



地理加权回归实验

GWR4 Semiparametric GWR/GWGL modelling tool

File (F) Help (H)

Step 1: Data >

Step 2: Model >

Step 3: Kernel >

Locational variables

ID key (optional)

001 TAZ < >

X coordinate (Lon)

002 POINT_X < >

Y coordinate (Lat)

003 POINT_Y < >

☐ Projected
☒ Spherical

Variable (Field) list

004 DISTRICT

005 area

006 pop_den

007 employ_de

008 high_edu_c

009 AvgIncome

010 lu_entropy

015 Mobile_d

017 road_d

Model settings

Model type

☒ Gaussian
☐ Poisson (count)
☐ Logistic (binary)

Options

☐ Standardisation of independent variables
☐ Geographical variability test
☐ L -> G variable-selection
☐ G -> L variable-selection

GWR4 Semiparametric GWR/GWGL modelling tool

File (F) Help (H)

Step 1: Data >

Step 2: Model >

Step 3: Kernel >

Step 4: Output >

Step 5: Execute



Execute this session

☐ Execute from a batch file

batch file (.bat) Browse

```

Degree of freedom (model: n - trace(S)): 448.792659
Degree of freedom (residual: n - 2trace(S) + trace(S'S)): 439.620463
ML based sigma estimate: 1295.477607
Unbiased sigma estimate: 1343.759449
-2 log-likelihood: 8121.952292
Classic AIC: 8172.366974
AICc: 8175.324128
BIC/MDL: 8277.206710
CV: 2057570.791982
R square: 0.591815
Adjusted R square: 0.560752

*****
<< Geographically varying (Local) coefficients >>
*****
Estimates of varying coefficients have been saved in the following file.

```

☐ First
 lines
☒ All

View the parameter estimates

课程自研项目汇报

